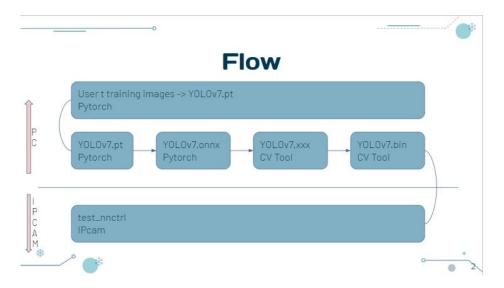
# 轉換流程圖



- ✓ 建立 VM ONNX (amba-cv-tools-basic.2.5.6.0.1245.ubuntu-20.04 SDK)
- ✓ 建立 VM SDKKK (cv2x\_sdk30\_patch9 SDK)
- ✓ 整體流程參考文件:
  - · VM SDK 文件: (In VM ONNX) /home/lilin/onnx\_code.txt
  - · lilin 文件:AmbaToOnnx\_環境及使用方式文件
  - · amba 文件:Ambarella\_CVflow\_CNNGen\_Basic\_Introduction\_v0p2\_20230213

# Step 1: YOLO PT weight -> ONNX

- ✓ yolov7 官網提供 export.py 可以直接轉譯,但有錯誤,修改後的編輯檔如 yolov7tpt\_2\_onnx.ipynb,可以直接上傳到 colab 執行
- ✓ yolov7tpt\_2\_onnx.ipynb 主要功能:
  - · 驗證 yolov7\_tiny.pt 推論
  - · 產生 yolov7\_tiny.onnx
  - · 驗證 yolov7\_tiny.onnx 推論

# Step 2: ONNX -> Modified ONNX

## 檢測 ONNX

- ✓ 參考 amba 文件: Ambarella-CV2x\_Onnx\_Utils\_Onnx\_Print\_Graph\_Summary
- ✓ 執行所有功能前都要先 VM Build enviroment:

## # Enter VM ONNX

### \$ source /usr/local/amba-cv-tools-basic.2.5.6.0.1245.ubuntu-20.04/env/cv22.env

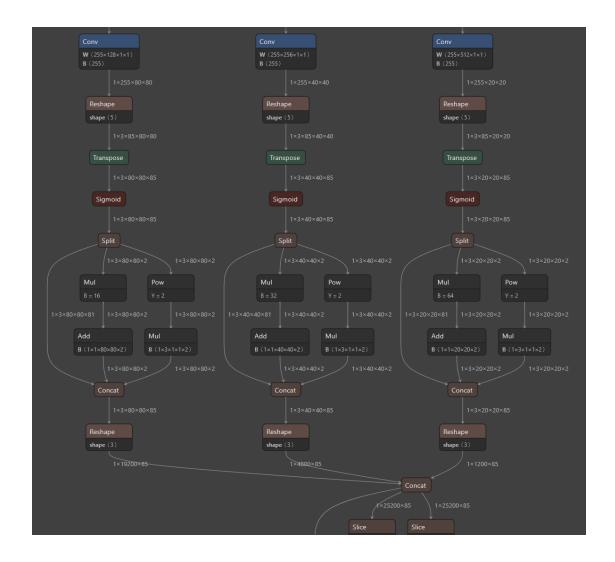
✓ 將 yolov7\_tiny.onnx 透過 amba 檢測程式 onnx\_print\_graph\_summary.py 查看有無不支援的內容:

\$ cd /usr/local/amba-cv-tools-basic.2.5.6.0.1245.ubuntu-20.04/cv2/tv2/release/CommonCnnUtils/cv2.basic.2.5.6.0.1245.ubu2004

\$ onnx\_print\_graph\_summary.py -p yolov7\_tiny.onnx

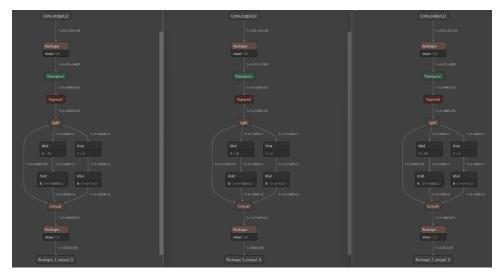
### ✓ 問題主要包含 3 個:

- · 部分 reshape layer 將 dimension 增加到 5,但 amba 不支援 dimension > 4 的 tensor
- · 不支援 NonMaxSuppression,其作用為過濾掉與先前選取的框具有較高交並集 (IOU) 重疊的框,刪除分數小於 score\_threshold 的邊界框
- · 不支援 cast,其作用為將輸入 tensor 轉換成指定的資料類型,並以轉換後的類型 傳回相同大小的輸出 tensor
- · 可以使用可視化工具查看架構的節點關係、名稱或 tensor 大小,方便找出有問題的 地方



## 修改維度

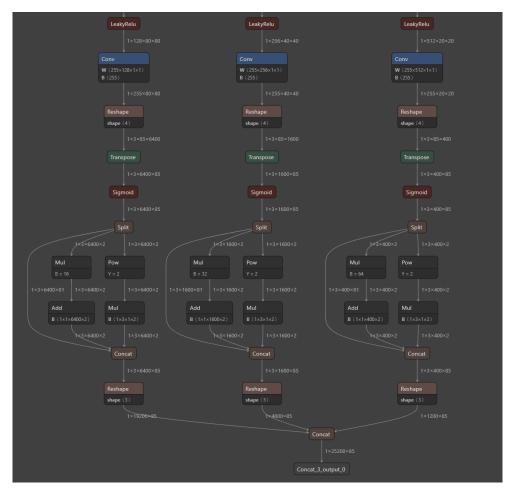
- ◆ 参考 amba 文件: Ambarella-CV2x\_Onnx\_Utils\_Onnx\_Graph\_Surgery · 章節 4.2.3
  Generating Replacement Subgraphs 有範例程式
- ✓ 目的:建立新的 subgraph ,取代掉原先不支援的局部架構
- ✓ 這邊把所有 5 維 tensor 的 80x80, 40x40, 20x20 特徵層合併成 6400, 1600, 400
  - · 可再評估不同的合併方式對模型效果的影響
- ✓ 重拉過需替換的部分,並注意替換的開頭和結尾節點命名和大小需與原架構相同,amba 的程式才能成功替換
- ✓ 下圖從左到右的 subgraph 建立程式依序為:replace\_1.py, replace\_2.py, replace\_3.py, 運行完會產生 3 個 onnx 檔:replace\_subgraph\_1.onnx, replace\_subgraph\_2.onnx, replace\_subgraph\_3.onnx



- ✓ 建立 config.json·將要替換的 3 個 onnx 檔資訊寫入·確保 node 命名符合原架構和新 架構
- ✓ 透過以下指令進行替換:
  - \$ cd /usr/local/amba-cv-tools-basic.2.5.6.0.1245.ubuntu-
  - 20.04/cv2/tv2/release/CommonCnnUtils/cv2.basic.2.5.6.0.1245.ubu2004
  - \$ graph\_surgery.py -fw onnx -m version1.onnx -t ReplaceSubgraph=path/to/config.json -o version2.onnx
  - # 如果出現 graph summary recommandations 就依照他上面建議用的透過 -t 加入
  - \$ graph\_surgery.py -fw onnx -m version2.onnx -t CVFlow

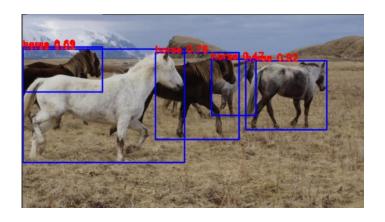
## 修改 NonMaxSuppression, Cast

- ✓ 參考連結中解釋了 Concat 的輸出 [1,25200,85] 含意:
  - · 1: Batch size
  - · 25200 = 3x(20x20+40x40+80x80): 總 Anchor box 數量 · 每個特徵點會對應 3 個 Anchor box · 20, 40, 80 分別為三個不同大小的特徵層
  - · 85 = (4+1+80):
    - 前 4 個參數用於判斷每一個特徵點的迴歸參數,回歸參數調整後可獲得Bounding Box 的位置
    - 第 5 個參數為 Bounding Box 的信心分數,用來判斷每一個特徵點是否包含預測類別
    - 。 最後 80 個參數為特徵點分別對 80 個 COCO 類別的預測分數。
- ✓ 目的:拿掉包含到 NonMaxSuppression, cast 的架構·將模型最後的 output 修改成 concat 的輸出
- ✓ output\_modified.py 程式最終調整完畢的模型架構為下圖 (接近模型輸出的地方):



✓ 再次執行檢測可看到輸入輸出正常,且已無問題

✓ 透過 inference.ipynb 將修正後的 onnx 輸出接出,並加入 NMS 在本機上推論進行 結果驗證,確認修改的模型沒有問題:



# Step 3: Modified ONNX -> amba bin

## input image

- ✓ 產生作為 IPCAM 的 input image bin 檔
- ✓ /dra\_img/ 裡面裝一張圖片就好,不然後面 onnxparser 會噴錯
- ✓ 執行完會產生出紀錄圖片路徑的 txt 檔和轉成 bin 檔的圖片

\$ cd /usr/local/amba-cv-tools-basic.2.5.6.0.1245.ubuntu-

20.04/cv2/tv2/release/CommonCnnUtils/cv2.basic.2.5.6.0.1245.ubu2004

\$ python3 gen\_image\_list.py \

-f /home/lilin/cnngen demo/onnx/demo networks/yolov7 tiny/dra img \

-0

/home/lilin/cnngen\_demo/out/demo\_networks/onnx\_yolov7s\_tiny/dra\_image\_bin/img\_list. txt> -ns \

-e jpg -c 0 -d 0,0 -r 640,640 \

-bf /home/lilin/cnngen\_demo/out/demo\_networks/onnx\_yolov7s\_tiny/dra\_image\_bin \

-bo

/home/lilin/cnngen\_demo/out/demo\_networks/onnx\_yolov7s\_tiny/dra\_image\_bin/dra\_bin\_ list.txt

### **Parser**

✓ 接下來產生很多 weight, layer bin 檔在 /dra\_image\_bin/ 中·也會包含
onnx\_yolov7t.json 檔

\$ cd /usr/local/amba-cv-tools-basic.2.5.6.0.1245.ubuntu-

20.04/cv2/tv2/release/AmbaCnnUtils/cv2.basic.2.5.6.0.1245.ubu2004/parser/onnx

\$ python3 onnxparser.py \

-m "/usr/local/amba-cv-tools-basic.2.5.6.0.1245.ubuntu-

20.04/cv2/tv2/release/CommonCnnUtils/cv2.basic.2.5.6.0.1245.ubu2004/version3.onnx"

-isrc

"is:1,3,640,640|iq|idf:0,0,8,0|i:images=/home/lilin/cnngen\_demo/out/demo\_networks/onnx \_yolov7s\_tiny/dra\_image\_bin/dra\_bin\_list.txt" \

-o "onnx\_yolov7t" \

-of "/home/lilin/cnngen\_demo/out/demo\_networks/onnx\_yolov7s\_tiny/dra\_image\_bin/" \

#### -odst "o:/model/model.77/Concat\_3\_output\_0|odf:fp32"

✓ 出現以下畫面表示成功

```
[info] drc proc time = 2.382 s @ 100 %
[info] drc num frames = 1
[info] drc proc time = 2.382277 s
[info] drc pproc time = 0.000652 s
[info] drc total time = 4.842634 s
[info] dr2 time = ( 2.591 calc + 3.369 stat) s x 1 frames
```

#### Acinference

✓ 執行完以下指令後,即可產生最終的 weight bin 檔:onnx\_yolov7t\_cavalry.bin

\$ cd /home/lilin/cnngen\_demo/out/demo\_networks/onnx\_yolov7s\_tiny/dra\_image\_bin

\$ acinference onnx\_yolov7t.json \

-i

images=/home/lilin/cnngen\_demo/out/demo\_networks/onnx\_yolov7s\_tiny/dra\_image\_bin/dra\_bin\_list.txt -o output

\$ vas -auto -show-progress onnx\_yolov7t.vas

\$ cavalry\_gen -V 2.2.8.1 -d vas\_output/ -f onnx\_yolov7t\_cavalry.bin -v

```
### State of the Company of the Comp
```

# Step 4: amba bin 輸出驗證

- ✓ 參考 amba 文件 (可搜關鍵字 test\_nnctrl):
  - · Ambarella\_CV2x\_UG\_Flexible\_Linux\_SDK3.0\_CNNGen\_Development\_Flow
  - Ambarella\_CV2x\_DG\_Flexible\_Linux\_SDK3.0\_CVflow\_FAQ
- ✓ 上傳到 IPCAM 推論單張圖片

### # IPCAM

\$ killall -9 inetd; rm /etc/inetd.conf; echo 221 stream tcp nowait root ftpd ftpd -w / >

/etc/inetd.conf ;inetd

\$ killall -9 monitor\_ipcam; killall -9 ipcam\_service

\$ tftp 192.168.50.200 -gr onnx\_yolov7t\_cavalry.bin

\$ tftp 192.168.50.200 -gr bus.bin

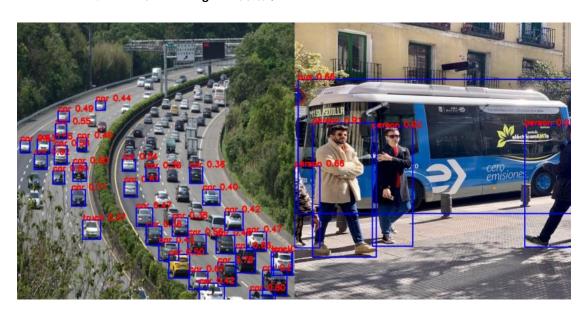
\$ modprobe cavalry;/usr/local/bin/cavalry\_load -f /lib/firmware/cavalry.bin -r

\$ test\_nnctrl -b onnx\_yolov7t\_cavalry.bin --in images=bus.bin --out

/model/model.77/Concat\_3\_output\_0=output.bin -e

\$ tftp -pr output.bin 192.168.50.200

✓ 就可以看到輸出一個 output.bin 檔,再透過 inference.ipynb 將模型的輸出接入 NMS 並產生畫出 Bounding Box 的結果圖



## LILIN\_SDK3.0.9

✓ 如果要調整 test\_nnctrl 就重新編譯後上傳到 IPCAM

# Enter VM SDKKK

\$ cd

/home/lilin/Desktop/sdk\_build/cv2x\_sdk30\_patch9/ambarella/boards/cv22\_walnut

\$ source ../../build/env/aarch64-linux5.4-gcc.env

\$ make test\_nnctrl

\$ sudo cp ../../out/cv22\_walnut/fakeroot/usr/local/bin/test\_nnctrl ~/Desktop/sdk/

## # IPCAM

\$ tftp 192.168.50.200 -gr test\_nnctrl

\$ chmod 777 test\_nnctrl

./test\_nnctrl -b onnx\_yolov7t\_cavalry.bin --in images=bus.bin --out

/model/model.77/Concat\_3\_output\_0=output.bin -e

```
Build libranctrl.so Done.
Build libranctrl.so Done.
Build librance.so Done.
Build test nnctrl live Done.
```

模型輸出的內容為 structure io\_match 的 \*virt\_addr,可以將 \*virt\_addr 轉成 float 型態印出查看,應與上面 output.bin 內容一樣: void print\_data\_as\_float(uint8\_t \*virt\_addr, uint32\_t data\_count, struct io\_data\_fmt \*data\_fmt) { float \*f32\_ptr; uint32\_t i; if (data\_fmt->size == 2) { // 32-bit float f32\_ptr = (float \*)virt\_addr; printf("Data as 32-bit float:\n"); for (i = 0; i < data\_count; i++) { printf("%f ", f32\_ptr[i]); } printf("\n"); } else { printf("Unsupported data size for floating-point format.\n"); }

}